

간헐적 관측 지연 환경에서 운동학적 상태 보정을 활용한 DQN 기반 자율주행 의사결정 성능 분석

정유림, 황상원*
부경대학교

yrjeong@pukyong.ac.kr, *s.won.hwang@pknu.ac.kr

Performance Analysis of DQN-Based Autonomous Driving Decision-Making with Kinematic State Compensation under Intermittent Observation Delays

Yurim Jeong, Sangwon Hwang*
Pukyong National University

요 약

본 논문은 간헐적인 1 단계 관측 지연이 DQN 기반 자율주행 의사결정에 미치는 영향을 분석하고, 등속도(CV), 등가속도(CA) 및 적응형 상태 보정 방법을 비교한다. HighwayEnv 에서 정상 관측으로 학습한 3 개의 DQN 모델을 평가한 결과, 지연 확률이 증가할수록 충돌률이 증가하고 평균 리턴과 생존 시간이 감소하였다. 지연 확률이 0.50 일 때 CV 보정은 위치 예측 오차를 10.44 m 에서 6.01 m 로, 충돌률을 74.0%에서 62.7%로 감소시켰다. 이를 통해 운동학적 상태 보정이 관측 지연에 따른 성능 저하를 일부 완화할 수 있음을 확인하였다.

I. 서 론

강화학습 기반 자율주행 시스템은 자차와 주변 차량의 위치 및 속도 등의 관측 정보를 바탕으로 주행 행동을 결정한다. 그러나 관측 지연이 발생하면 에이전트가 실제 교통 상황이 아닌 과거 상태를 이용하여 행동하므로 현재 교통 상황과 맞지 않는 차선이나 목표 속도를 선택하여 충돌 위험이 증가할 수 있다. 관측 및 행동 지연을 고려한 강화학습 연구가 수행되어 왔으나[1], 본 연구에서는 정책을 다시 학습하지 않고 DQN 입력 앞단에서 지연 관측을 보정하는 방법을 검토한다.

본 연구에서는 HighwayEnv 에서 정상 관측으로 학습된 DQN 정책에 확률적인 1 단계 관측 지연을 적용하고, 미보정·등속도·등가속도 및 적응형 보정 방법을 비교한다. 이를 통해 관측 지연이 자율주행 의사결정에 미치는 영향을 정량적으로 분석하고, 운동학적 상태 보정의 효과와 지연 조건에 따른 한계를 확인한다.

II. 시스템 모델 및 문제 정의

본 연구에서는 자율주행 의사결정 환경으로 HighwayEnv 의 highway-fast-v0 를 사용하였다[2]. 실험 환경은 3 개 차선과 20 대의 차량으로 구성되며, 차량 동역학과 DQN 정책 결정 주기는 각각 5 Hz 와 1 Hz 로 설정하였다. DQN 은 LANE_LEFT, IDLE, LANE_RIGHT, FASTER, SLOWER 중 하나의 고수준 행동을 선택하고, 선택된 목표 차선과 속도는 HighwayEnv 의 저수준 제어기에 의해 실행된다.

HighwayEnv 의 실제 상태 s_t , DQN 에 전달되는 정상 관측을 o_t 라 한다. 관측은 자차와 주변 차량을 포함한 최대 $N = 5$ 대의 차량으로 구성되며 다음과 같이 표현한다.

$$o_t = [z_{0,t}, z_{1,t}, \dots, z_{N-1,t}]^T, \quad z_{i,t} = [c_{i,t}, x_{i,t}, y_{i,t}, v_{x,i,t}, v_{y,i,t}]^T$$

여기서 $c_{i,t}$ 는 차량의 존재 여부를 나타내는 presence 값이고, $x_{i,t}, y_{i,t}$ 와 $v_{x,i,t}, v_{y,i,t}$ 는 자차 기준 상대 위치와 상대속도이다. 주변 차량은 거리순으로 정렬되며 각 관측값은 DQN 입력 전에 정규화된다. 보상은 충돌, 우측 차선 및 고속 주행 항에 각각 -1, 0.1, 0.4 의 가중치를 적용한 뒤 정규화하며, 에피소드는 자차가 충돌하거나 최대 주행 시간인 30 초에 도달하면 종료된다.

본 연구에서는 자차와 주변 차량을 포함한 전체 관측 정보의 처리 지연을 가정한다. 각 의사결정 시점에서 지연 발생 여부를 독립적으로 결정하고, 확률 p 로 직전 관측이 DQN 에 전달되며 DQN 에 실제로 입력되는 관측 $\tilde{o}_t$ 는 다음과 같다.

$$\tilde{o}_t = \begin{cases} o_{t-1}, & p, \\ o_t, & 1-p. \end{cases}$$

정책 결정 주기가 1 Hz 이므로 1 단계 관측 지연은 $\Delta t = 1$ 초이다. 지연은 DQN 입력에만 적용하고 실제 차량 움직임, 보상 및 종료 조건에는 적용하지 않는다. 본 연구의 목적은 학습된 DQN 의 구조와 가중치를 고정한 상태에서 지연 관측 $\tilde{o}_t$ 를 현재 시점의 입력 o_t 로 보정하여 성능 저하를 완화하는 것이다. 그림 1 은 관측 지연과 상태 보정을 포함한 자율주행 의사결정 구조를 나타낸다.




그림 1. 관측 지연 보정 기반 자율주행 의사결정 구조

III. 제안 상태 보정 방법

본 연구에서는 DQN 입력단에 상태 보정 모듈을 배치한다. 정상 관측은 그대로 사용하고, 지연이 발생한 경우에는 위치와 속도가 유효한 차량을 대상으로 현재 상태를 예측한다. 정규화된 관측값은 실제 단위로 역정규화하여 보정한 뒤 다시 정규화하여 DQN에 입력한다.

등속도(Constant Velocity, CV) 보정은 지연 시간 동안 차량의 상대속도가 일정하다고 가정한다. 직전 시점의 위치와 속도를 각각 r_{t-1} 과 u_{t-1} 이라 하면 현재 상태는 다음과 같이 예측한다.

$$\widehat{r}_t^{CV} = r_{t-1} + u_{t-1}\Delta t, \quad \widehat{u}_t^{CV} = u_{t-1}$$

등가속도(Constant Acceleration, CA) 보정은 최근 두 시점의 상대속도 차이로 가속도를 추정하여 차량의 가.감속을 반영한다.

$$\widehat{a}_{t-1} = \frac{u_{t-1} - u_{t-2}}{\Delta t}$$

$$\widehat{r}_t^{CA} = r_{t-1} + u_{t-1}\Delta t + \frac{1}{2}\widehat{a}_{t-1}\Delta t^2, \quad \widehat{u}_t^{CA} = u_{t-1} + \widehat{a}_{t-1}\Delta t.$$

비현실적인 가속도 추정을 방지하기 위해 종.횡방향 가속도를 각각 $[-6,6]$ 과 $[-4,4]$ m/s^2 로 제한하였다. 적응형 보정은 정상 관측이 수신된 시점에 CV 와 CA 의 직전 위치 예측 오차를 다음과 같이 누적한다.

$$E_{t-1}^m = 0.3e_{t-1}^m + 0.7E_{t-2}^m, \quad m \in \{CV, CA\}$$

최소 3 회의 오차 갱신 후 $E_{t-1}^{CA} < 0.95E_{t-1}^{CV}$ 인 경우에는 CA 를, 그 외에는 CV 를 선택한다. 모델 선택에는 실제 상태를 사용하지 않고 이전에 수신된 관측과 예측 오차만 이용하였다. 연속 관측에서는 차량 행의 순서가 달라질 수 있으므로, 위치 기준 15 m 이내에서 차량을 대응시키고, 대응되지 않은 차량은 CV 로 보정하였다. presence=0 인 차량은 보정 대상에서 제외하였다.

IV. 실험 설정 및 결과

DQN[3]은 Stable-Baselines3[4]로 구현하였다. 정책 신경망은 256 개 뉴런의 은닉층 2 개로 구성하였으며, 학습률 5×10^{-4} , 할인율 0.8, 리플레이 버퍼 크기 15,000, 미니배치 크기 32 로 설정하였다. 정상 관측 환경에서 서로 다른 3 개의 난수 시드로 각각 50,000 타임스텝 동안 학습하였다.

지연 확률은 $p \in \{0, 0.25, 0.50, 0.75, 1.00\}$ 으로 설정하였다. $p=0$ 에서는 지연 없음 조건을 평가하고, $p>0$ 에서는 미보정, CV, CA 및 적응형 보정을 동일한 DQN 과 평가 시드에서 비교하였다. 각 모델·조건 조합은 100 개 에피소드에서 결정론적으로 평가하였다. 3 개 모델에 대해 17 개 조건을 평가하여 5,100 개의 평가 에피소드를 수행하였으며, 평균 리턴, 충돌률, 생존 시간 및 위치 예측 오차를 측정하였다.

표 1. 정상 관측 및 $p=0.50$ 지연 조건의 평가 결과

방법	평균 리턴	충돌률 (%)	생존 시간 (s)	위치 오차 (m)
지연 없음	22.760	32.3	25.89	-
미보정	15.676	74.0	18.19	10.44
CV	17.188	62.7	20.01	6.01
CA	16.531	66.3	19.32	6.25
적응형	17.197	64.0	20.02	6.11

지연 확률이 증가할수록 미보정 조건의 평균 리턴과 생존 시간은 감소하고 충돌률은 증가하였다. 지연이 없는 조건의 충돌률은 32.3%였으나, $p=1.00$ 의 미보정 조건에서는 94.3%까지 증가하여 과거 관측이 DQN 의

주행 안정성을 저하시키는 것을 확인하였다. $p=0.50$ 에서 CV 보정은 위치 오차를 10.44 m에서 6.01 m로 줄이고 충돌률을 74.0%에서 62.7%로 낮췄으며, 평균 리턴과 생존 시간도 각각 15.676 에서 17.188, 18.19 초에서 20.01 초로 증가시켰다. 이때 충돌률의 시드 간 표준편차는 미보정 조건의 9.2%p 에서 CV 조건의 4.9%p 로 감소하였다.

보정 방법의 상대적 성능은 지연 조건에 따라 달랐다. CA 는 $p=0.25$ 에서 46.7%로 가장 낮은 충돌률을 보였고, $p=1.00$ 에서는 미보정 조건의 충돌률을 94.3%에서 83.0%로 낮췄다. 반면 $p=0.50$ 과 0.75 에서는 CV 가 각각 62.7%와 77.3%로 가장 우수하였다. 적응형 보정은 전반적으로 CV 와 유사한 성능을 보였으나 모든 조건에서 최적 성능을 나타내지는 않았다. 이는 단일 속도 차이로 추정한 가속도가 차선 변경과 급격한 속도 변화를 안정적으로 반영하기 어렵고, 보수적인 오차 기반 선택 조건으로 인해 CV 가 주로 선택되었기 때문으로 해석된다. 그림 2 는 지연 확률에 따른 상태 보정 방법별 평균 충돌률을 나타내며, 오차 막대는 3 개 학습 시드에서 측정된 충돌률의 표준편차를 의미한다.




그림 2. 관측 지연 확률에 따른 상태 보정 방법별 충돌률

V. 결론

본 연구에서는 간헐적인 1 단계 관측 지연이 DQN 기반 자율주행 의사결정에 미치는 영향과 상태 보정의 효과를 분석하였다. 지연 확률이 증가할수록 주행 성능과 안정성이 저하되었으나, CV·CA 및 적응형 보정은 이를 일부 완화하였다. 다만 높은 지연 확률에서는 보정 후에도 충돌률이 높게 나타나 단순 운동 모델의 한계를 확인하였다. 향후에는 차량의 가.감속과 차선 변경을 반영하는 시계열 기반 상태 예측과 지연 인식 정책 학습을 적용하여 보정 성능을 개선하고자 한다.

참고 문헌

- [1] Y. Bouteiller, S. Ramstedt, G. Beltrame, C. J. Pal, and J. Binas, "Reinforcement Learning with Random Delays," Proc. International Conference on Learning Representations (ICLR), 2021.
- [2] E. Leurent, "An Environment for Autonomous Driving Decision-Making," GitHub repository, 2018. [Online]. Available: <https://github.com/Farama-Foundation/HighwayEnv>
- [3] V. Mnih et al., "Human-Level Control through Deep Reinforcement Learning," Nature, vol. 518, pp. 529–533, 2015.
- [4] A. Raffin, A. Hill, A. Gleave, A. Kanervisto, M. Ernestus, and N. Dormann, "Stable-Baselines3: Reliable Reinforcement Learning Implementations," Journal of Machine Learning Research, vol. 22, no. 268, pp. 1–8, 2021.